

CONȚINUTUL CURSULUI #5:

II.4. Metode iterative de rezolvare a sistemelor de ecuații liniare.

- II.4.1. Metode iterative de aproximare.
- II.4.2. Metoda Jacobi.
- II.4.3. Metoda Jacobi pentru matrice diagonal dominante pe linii.
- II.4.4. Metoda Jacobi relaxată.
- II.4.5. Metoda Gauss - Seidel relaxată.

II. Metode numerice de rezolvare a sistemelor liniare.
II.4. Metode iterative de rezolvare a sistemelor de ecuații liniare.

II.4.1. Metode iterative de aproximare.

Fie $A, B \in \mathcal{M}_n(\mathbb{R})$, $a, b \in \mathbb{R}^n$. Considerăm sistemul compatibil determinat

$$Ax = a \tag{1}$$

și un sistem echivalent

$$x = Bx + b \tag{2}$$

Definiția (II.12.)

O metodă iterativă de aproximare a soluției sistemului de ecuații liniare (1) presupune construcția unui șir recurent $(x^{(k)})_{k \in \mathbb{N}}$ conform formulei:

$$x^{(k+1)} = Bx^{(k)} + b, \quad x^{(0)} \in \mathbb{R}^n \text{ arbitrar} \tag{3}$$

Metoda iterativă (3) este convergentă dacă și numai dacă $\lim_{k \rightarrow \infty} x^{(k)} = x$, unde x este soluția sistemului (1).

Definiția (II.13.)

Fie $A \in \mathcal{M}_n(\mathbb{R})$. Se definește raza spectrală $\rho(A)$ a matricei A astfel:

$$\rho(A) = \max_{1 \leq i \leq n} |\lambda_i| \tag{4}$$

unde $\lambda_i \in \sigma(A)$, $i = \overline{1, n}$. Dacă $\lambda = a + bi \in \mathbb{C}$ atunci $|\lambda| = \sqrt{a^2 + b^2}$.

Definiția (II.14.)

Matricea $A \in \mathcal{M}_n(\mathbb{R})$ se numește convergentă dacă șirul de matrice format din puterile A^k ale matricei A este convergent la matricea nulă (sau componentele puterii matricei A tind la zero). Vom scrie:

$$\lim_{k \rightarrow \infty} A^k = O_n \tag{5}$$

sau

$$\lim_{k \rightarrow \infty} (A^k)_{ij} = 0, \quad i, j = \overline{1, n} \tag{6}$$

Propoziția (II.5.)

Fie $A \in \mathcal{M}_n(\mathbb{R})$. Următoarele afirmații sunt echivalente:

- a) A este o matrice convergentă;
- b) $\lim_{k \rightarrow \infty} \|A^k\| = 0$;
- c) $\lim_{k \rightarrow \infty} A^k x = 0_n, \forall x \in \mathbb{R}^n$;
- d) $\rho(A) < 1$.

Propoziția (II.6.)

Fie $A \in \mathcal{M}_n(\mathbb{R})$. Atunci

$$\rho(A) \leq \|A\| \tag{7}$$

pentru orice normă matriceală $\|\cdot\|$ subordonată unei norme vectoriale.

Demonstrație: Fie $\lambda \in \sigma(A)$ și fie x vectorul propriu asociat valorii proprii λ cu proprietatea $\|x\| = 1$. Atunci $Ax = \lambda x$ de unde rezultă

$$\|Ax\| = |\lambda| \|x\| = |\lambda|$$

Pe de altă parte

$$\|Ax\| \leq \|A\| \|x\| \leq \|A\|$$

Din aceste relații rezultă $\rho(A) = \max_{\lambda \in \sigma(A)} |\lambda| \leq \|A\|$.

Propoziția (II.7.)

Fie $A \in \mathcal{M}_n(\mathbb{R})$ cu $\|A\| < 1$, atunci

$$\exists (I_n - A)^{-1} \text{ și } \|(I_n - A)^{-1}\| \leq \frac{1}{1 - \|A\|} \quad (8)$$

Demonstrație: Dacă $\lambda_i, i = \overline{1, n}$ sunt valorile proprii ale matricei A atunci $1 - \lambda_i, i = \overline{1, n}$ sunt valorile proprii ale matricei $I_n - A$. Deoarece $\rho(A) < 1$ rezultă $|\lambda_i| < 1, i = \overline{1, n}$, iar $1 - \lambda_i \neq 0, i = \overline{1, n}$, deci $I_n - A$ este inversabilă. În continuare să observăm următoarea egalitate:

$$(I_n - A)(I_n + A + A^2 + \dots + A^k) = I_n - A^{k+1} \quad (9)$$

Curs #5

March 26, 2018 5 / 26

$$\begin{aligned} \lim_{k \rightarrow \infty} x^{(k)} \rightarrow x &\Leftrightarrow \lim_{k \rightarrow \infty} B^k(x^{(0)} - x) = 0, \forall x^{(0)} \in \mathbb{R}^n \Leftrightarrow \\ &\Leftrightarrow \lim_{k \rightarrow \infty} B^k = 0_n \Leftrightarrow \rho(B) < 1 \quad (\text{conform Prop. II.5.}) \end{aligned}$$

Teorema (II.11.)

Dacă $\|B\| = q, q \in (0, 1)$, atunci metoda iterativă (3) este convergentă și are loc următoarea estimare a erorii:

$$\|x^{(k)} - x\| \leq \frac{q^k}{1 - q} \|x^{(1)} - x^{(0)}\|, \forall k \in \mathbb{N}^* \quad (14)$$

Demonstrație: Deoarece $\|B\| < 1$, atunci conform Prop. II.7. rezultă că $\exists (I - B)^{-1}$ și $\|(I - B)^{-1}\| \leq \frac{1}{1 - \|B\|} = \frac{1}{1 - q}$

Evaluăm diferența $x^{(k+1)} - x^{(k)}$:

$$\begin{aligned} x^{(k+1)} - x^{(k)} &= Bx^{(k)} + b - x^{(k)} = Bx^{(k)} - Bx^{(k-1)} \\ &= B(x^{(k)} - x^{(k-1)}) \Rightarrow \end{aligned}$$

Curs #5

March 26, 2018 7 / 26

sau

$$I_n + A + A^2 + \dots + A^k = (I_n - A)^{-1}(I_n - A^{k+1}) \quad (10)$$

Trecând la limită în relația de mai sus și ținând cont că $\lim_{k \rightarrow \infty} A^{k+1} = O_n$ se obține următoarea estimare:

$$\|(I_n - A)^{-1}\| = \left\| \sum_{k=0}^{\infty} A^k \right\| \leq \sum_{k=0}^{\infty} \|A^k\| \leq \sum_{k=0}^{\infty} \|A\|^k = \frac{1}{1 - \|A\|} \quad (11)$$

Teorema (II.10.)

Fie $A \in \mathcal{M}_n(\mathbb{R})$ inversabilă, $a \in \mathbb{R}^n$ și o metodă iterativă (3) de aproximare a soluției sistemului de ecuații liniare $Ax = a$ definită de sistemul echivalent $x = Bx + b$. Atunci metoda iterativă este convergentă dacă și numai dacă

$$\rho(B) < 1 \quad (12)$$

Demonstrație: Fie $x^{(0)} \in \mathbb{R}^n$

$$\begin{aligned} x^{(k)} - x &= Bx^{(k-1)} + b - x = Bx^{(k-1)} - Bx \\ &= B(x^{(k-1)} - x) = \dots = B^k(x^{(0)} - x) \Rightarrow \end{aligned} \quad (13)$$

Curs #5

March 26, 2018 6 / 26

$$\|x^{(k+1)} - x^{(k)}\| \leq \|B\| \|x^{(k)} - x^{(k-1)}\| = q \|x^{(k)} - x^{(k-1)}\|$$

Evaluăm $(I - B)(x^{(k)} - x)$:

$$\begin{aligned} (I - B)(x^{(k)} - x) &= x^{(k)} - Bx^{(k)} - x + Bx \\ &= x^{(k)} - Bx^{(k)} - b + x^{(k)} - x^{(k+1)} \Rightarrow \end{aligned}$$

$$\begin{aligned} x^{(k)} - x &= (I - B)^{-1}(x^{(k)} - x^{(k+1)}) \\ &= (I - B)^{-1}B(x^{(k-1)} - x^{(k)}) \Rightarrow \end{aligned}$$

$$\begin{aligned} \|x^{(k)} - x\| &\leq \|(I - B)^{-1}B\| \|x^{(k)} - x^{(k-1)}\| \\ &\leq \frac{q}{1 - q} \|x^{(k)} - x^{(k-1)}\| \leq \dots \leq \frac{q^k}{1 - q} \|x^{(1)} - x^{(0)}\| \end{aligned}$$

Deoarece $q \in (0, 1) \Rightarrow \lim_{k \rightarrow \infty} \frac{q^k}{1 - q} = 0 \Rightarrow (x^{(k)})_{k \geq 0}$ converge la x , deci metoda iterativă este convergentă.

Curs #5

March 26, 2018 8 / 26

II.4.2. Metoda Jacobi

Fie $A \in \mathcal{M}_n(\mathbb{R})$ o matrice inversabilă, $a \in \mathbb{R}^n$, atunci sistemul $Ax = a$ este echivalent cu $x - Ax = x - a$ sau $x = (I - A)x + a$. Considerând $B = I - A$, $b = a$, obținem sistemul $x = Bx + b$ în baza căruia se construiește metoda iterativă Jacobi.

Conform Th. II.10. metoda Jacobi este convergentă dacă și numai dacă $\rho(B) < 1$. Mai mult, dacă $\|B\| = q \in (0, 1)$, atunci conform Th. II.11. rezultă că metoda Jacobi este convergentă și are loc estimarea:

$$\|x^{(k)} - x\| \leq \frac{q^k}{1 - q} \|x^{(1)} - x^{(0)}\|, \quad k \in \mathbb{N}^* \quad (15)$$

ALGORITM (Metoda Jacobi)

Date de intrare: $A = (a_{ij})_{i,j=1,n} \in \mathcal{M}_n(\mathbb{R})$ - inv.; $a \in \mathbb{R}^n$; ε .

Date de ieșire: $x_{\text{aprox}} \in \mathbb{R}^n$; N .

```
STEP 1: Se determină  $q = \|I - A\|$ ;  
if  $q \geq 1$  then  
    OUTPUT('Metoda Jacobi nu asigură conv.')  
    STOP  
endif  
STEP 2: Se inițializează  $x^{(0)} = 0$ ;  $k = 0$ ;  
STEP 3: Determină:  $B = I - A$ ;  $b = a$ ;  
STEP 4: do  
     $k = k + 1$ ;  
     $x^{(k)} = Bx^{(k-1)} + b$ ;  
    while  $\frac{q^k}{1 - q} \|x^{(1)} - x^{(0)}\| \geq \varepsilon$ ;  
STEP 5:  $x_{\text{aprox}} = x^{(k)}$ ,  $N = k$ .
```

II.4.3. Metoda Jacobi pentru matrice diagonale dominante pe linii

Metoda Jacobi poate fi aplicată doar pentru o clasă restrânsă de matrice. În cele ce urmează vom prezenta metoda Jacobi pentru o clasă de matrice, pentru care această metodă este convergentă.

Definiția (II.15.)

Fie $A = (a_{ij})_{i,j=1,n} \in \mathcal{M}_n(\mathbb{R})$

a) Spunem că A este diagonal dominantă pe linii dacă

$$|a_{ii}| > \sum_{j=1, n, j \neq i} |a_{ij}|, \quad i = \overline{1, n}$$

b) Spunem că A este diagonal dominantă pe coloane dacă

$$|a_{jj}| > \sum_{i=1, n, i \neq j} |a_{ij}|, \quad j = \overline{1, n}$$

Fie $D = \text{diag}(A) = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$. Se observă că $|a_{ii}| > 0$, $i = \overline{1, n}$, deci D este inversabilă. Atunci sistemul $Ax = a$ este echivalent cu $D^{-1}Ax = D^{-1}a$ sau $x = (I - D^{-1}A)x + D^{-1}a$. Considerând $B = I - D^{-1}A$, $b = D^{-1}a$ se obține sistemul $x = Bx + b$.

Teorema (II.12.)

Fie sistemul $Ax = a$ cu A matrice nesingulară și diagonal dominantă pe linii, și sistemul echivalent $x = Bx + b$, unde $B = I - D^{-1}A$, $b = D^{-1}a$. Fie $q = \|B\|_\infty$ și $(x^{(k)})_{k \in \mathbb{N}}$ definit prin formula

$$x^{(k)} = Bx^{(k-1)} + b \quad (16)$$

Atunci $q < 1$ și $\|x^{(k)} - x\|_\infty \leq \frac{q^k}{1 - q} \|x^{(1)} - x^{(0)}\|_\infty$, $k \in \mathbb{N}^*$.

Demonstrație: Componentele matricei $B = I - D^{-1}A$ se pot reprezenta după cum urmează:

$$b_{ij} = \delta_{ij} - d_{ik}^{-1}a_{kj} = \delta_{ij} - \frac{a_{ij}}{a_{ii}} = \begin{cases} 0, & i = j \\ -\frac{a_{ij}}{a_{ii}}, & i \neq j \end{cases}$$

Pe de altă parte, evaluând norma infinit a matricei B , se obține:

$$q = \|B\|_{\infty} = \max_{i=\overline{1,n}} \sum_{j=\overline{1,n}} |b_{ij}| = \max_{i=\overline{1,n}} \sum_{j=\overline{1,n}, j \neq i} \frac{|a_{ij}|}{|a_{ii}|} \Rightarrow$$

$$q = \max_{i=\overline{1,n}} \frac{\sum_{j=\overline{1,n}, j \neq i} |a_{ij}|}{|a_{ii}|} < 1$$

Conform Th. II.11. rezultă că metoda iterativă este convergentă și are loc estimarea din enunț.

ALGORITM (Metoda Jacobi pentru matrice diagonal dominante pe linii')

Date de intrare: $A = (a_{ij})_{i,j=\overline{1,n}} \in \mathcal{M}_n(\mathbb{R})$ - inv.; $a \in \mathbb{R}^n$; ε .

Date de ieșire: $x_{\text{approx}} \in \mathbb{R}^n$; N .

STEP 1: for $i=\overline{1:n}$ do

if $|a_{ii}| \leq \sum_{j=\overline{1,n}, j \neq i} |a_{ij}|$ then

OUTPUT('Matr. nu este diag. dom. pe linii')

STOP.

endif

endfor

STEP 2: Se inițializează: $x^{(0)} = 0$; $k = 0$;

STEP 3: Determină: $b_{ij} = \delta_{ij} - \frac{a_{ij}}{a_{ii}}$, $i, j = \overline{1, n}$; $b_i = \frac{a_i}{a_{ii}}$, $i = \overline{1, n}$;

$q = \|B\|_{\infty}$;

STEP 4: do

$k = k + 1$;

$x^{(k)} = Bx^{(k-1)} + b$; (B, b au fost calculați la STEP 3)

while $\frac{q^k}{1-q} \|x^{(1)} - x^{(0)}\|_{\infty} \geq \varepsilon$

STEP 5: $x_{\text{approx}} = x^{(k)}$; $N = k$;

II.4.4. Metoda Jacobi relaxată

Metoda Jacobi relaxată este o variantă îmbunătățită a metodei Jacobi și constă în introducerea unui parametru $\sigma > 0$, numit parametru de relaxare. Fie $A \in \mathcal{M}_n(\mathbb{R})$ o matrice simetrică și pozitiv definită, $a \in \mathbb{R}^n$. Sistemul $Ax = b$ este echivalent cu $\sigma Ax = \sigma a$ sau $(I - \sigma A)x = x - \sigma a$, deci

$$x = B_{\sigma}x + b_{\sigma}, \quad \sigma > 0 \quad (17)$$

cu $B_{\sigma} = I - \sigma A$, $b_{\sigma} = \sigma a$. Pentru $\sigma = 1$ avem metoda Jacobi.

Teorema (II.13.)

Fie $\lambda_n \geq \lambda_{n-1} \geq \dots \geq \lambda_1 > 0$ valorile proprii ale matricei $A \in \mathcal{M}_n(\mathbb{R})$ simetrice și pozitiv definite. Atunci metoda Jacobi relaxată este convergentă dacă și numai dacă

$$\sigma \in \left(0, \frac{2}{\rho(A)}\right) \quad (18)$$

Mai mult, dacă $q = \rho(B_{\sigma}) = \max_{i=\overline{1,n}} |1 - \sigma \lambda_i|$, atunci $q < 1$ și avem următoarea estimare a erorii

$$\|x^{(k)} - x\|_A \leq \frac{q^k}{1-q} \|x^{(1)} - x^{(0)}\|_A \quad (19)$$

unde $\|x\|_A = \sqrt{Ax, x} = \sqrt{\sum_{i,j=1}^n a_{ij}x_jx_i}$.

Demonstrație: Deoarece A este simetrică și pozitiv definită rezultă că A este inversabilă, deci sistemul $Ax = a$ admite soluția unică x .

Metoda iterativă construită în baza formulei (17) este convergentă dacă și numai dacă $\rho(B_\sigma) < 1$. În cele ce urmează vom deduce condiția pe care trebuie să o satisfacă σ astfel încât $\rho(B_\sigma) < 1$. Valorile proprii ale matricei $I - \sigma A$ sunt $1 - \sigma\lambda_1, \dots, 1 - \sigma\lambda_n$. Într-adevar, fie λ este o valoare proprie a matricei A . Atunci

$$\det((I_n - \sigma A) - (1 - \sigma\lambda)I_n) = 0 \Leftrightarrow \det(A - \lambda I) = 0$$

Avem următoarele echivalențe

$$\rho(I_n - \sigma A) < 1 \Leftrightarrow \max_{i=\overline{1,n}} |1 - \sigma\lambda_i| < 1 \Leftrightarrow -1 < 1 - \sigma\lambda_i < 1, i = \overline{1,n}$$

Deoarece $\lambda_n \geq \lambda_{n-1} \geq \dots \geq \lambda_1 > 0 \Rightarrow$

$$1 > 1 - \sigma\lambda_1 \geq \dots \geq 1 - \sigma\lambda_n > -1 \Rightarrow \begin{cases} 1 > 1 - \sigma\lambda_1 \\ 1 - \sigma\lambda_n > -1 \end{cases} \Rightarrow \sigma \in \left(0, \frac{2}{\lambda_n}\right)$$

Astfel se demonstrează prima parte a teoremei.

Se observă că $q = \rho(B_\sigma) = \rho(I_n - \sigma A) < 1$. Pentru a demonstra formula (19) este necesar să demonstrăm, conform Th. II.11. că $\|B_\sigma\|_A = q$. Deoarece matricea A este simetrică și pozitiv definită, atunci $\exists B = \{u_1, \dots, u_n\} \subset \mathbb{R}^n$ o bază ortonormată formată din vectori proprii asociați valorilor proprii $\lambda_i > 0, i = \overline{1,n}$.

În baza vectorilor proprii ortonormați, putem construi o bază A -ortonormată dacă alegem $v_i = \frac{u_i}{\sqrt{\lambda_i}}, i = \overline{1,n}$. Într-adevăr,

$$\begin{aligned} \langle Av_i, v_j \rangle &= \left\langle A \frac{u_i}{\sqrt{\lambda_i}}, \frac{u_j}{\sqrt{\lambda_j}} \right\rangle = \left\langle \lambda_i \frac{u_i}{\sqrt{\lambda_i}}, \frac{u_j}{\sqrt{\lambda_j}} \right\rangle \\ &= \frac{\lambda_i \delta_{ij}}{\sqrt{\lambda_i} \sqrt{\lambda_j}} = \begin{cases} 1, i = j \\ 0, i \neq j \end{cases} \end{aligned}$$

Fie $v \in \mathbb{R}^n \setminus \{0\}$. Atunci $\exists \alpha_i, i = \overline{1,n}$ astfel încât $v = \sum_{i=1}^n \alpha_i v_i$. Evaluăm în continuare $\|v\|_A, \|B_\sigma v\|_A$:

Atunci

$$\begin{aligned} \|B_\sigma v\|_A^2 &= \langle AB_\sigma v, B_\sigma v \rangle = \langle AB_\sigma \frac{u_k}{\sqrt{\lambda_k}}, B_\sigma \frac{u_k}{\sqrt{\lambda_k}} \rangle \\ &= \frac{1}{\lambda_k} \langle A(1 - \sigma\lambda_k)u_k, (1 - \sigma\lambda_k)u_k \rangle = (1 - \sigma\lambda_k)^2 \Rightarrow \\ \frac{\|B_\sigma v\|_A}{\|v\|_A} &= q \geq q \Rightarrow \|B_\sigma\|_A \geq q \end{aligned} \quad (21)$$

Din inegalitățile (20) și (21) rezultă $\|B_\sigma\|_A = q$.

Definiția (II.16.)

Numim parametru optim de relaxare pentru metoda Jacobi relaxată (îl notăm σ_O) acea valoare a lui σ pentru care $q = \|B_\sigma\|_A$ (îl notăm q_O) are valoare minimă.

Propoziția (II.8.)

Parametrul optim de relaxare σ_O , respectiv q_O se calculează conform relațiilor:

$$\sigma_O = \frac{2}{\lambda_n + \lambda_1}, \quad q_O = \frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1}$$

Fie k astfel încât $|1 - \sigma\lambda_k| = q$.

$$\|B_\sigma\|_A \leq q \quad (20)$$

Obs.: Deoarece $\rho(A) \leq \|A\|$ rezultă $\frac{2}{\|A\|} \leq \frac{2}{\rho(A)}$. În practică vom

considera $\sigma \in \left(0, \frac{2}{\|A\|}\right)$.

ALGORITHM (Metoda Jacobi relaxată)

Date de intrare: $A \in \mathcal{M}_n(\mathbb{R})$ - sim. și poz. def.;

$a \in \mathbb{R}^n$; ε ; σ .

Date de ieșire: $x_{aprox} \in \mathbb{R}^n$; N .

STEP 1: Determină: $b_{ij} = \delta_{ij} - \sigma a_{ij}$, $i, j = \overline{1, n}$; $b_i = \sigma a_i$, $i = \overline{1, n}$;

STEP 2: Se inițializează: $x^{(0)} = 0$; $k = 0$;

STEP 3: do

$k = k + 1$

$x^{(k)} = B_\sigma x^{(k-1)} + b_\sigma$;

(B_σ, b_σ au fost calculați la STEP 1)

while $\frac{\|x^{(k)} - x^{(k-1)}\|_A}{\|x^{(k-1)}\|_A} \geq \varepsilon$

STEP 4: $x_{aprox} = x^{(k)}$; $N = k$.

Curs #5

March 26, 2018

21 / 26

ALGORITHM (Determinarea numerică a parametrului optim și a soluției aproximative corespunzătoare)

Date de intrare: $A \in \mathcal{M}(\mathbb{R})$ - sim. poz. def.; $a \in \mathbb{R}^n$; ε .

Date de ieșire: $x_{aprox}^O \in \mathbb{R}^n$; N_O ; σ_O .

STEP 1: for $s=1:p-1$ do

$\sigma_s = \frac{2s}{\|A\|_\infty p}$;

$[x_{aprox}, N] = \text{MetJacobiR}(A, a, \varepsilon, \sigma_s)$;

$V_s = N$;

endfor

STEP 2: Determină s a.î. $V_s = \min\{V_1, \dots, V_{p-1}\}$

$\sigma_O = \frac{2s}{\|A\|_\infty p}$;

STEP 3: $[x_{aprox}^O, N_O] = \text{MetJacobiR}(A, a, \varepsilon, \sigma_O)$.

Curs #5

March 26, 2018

23 / 26

Fie procedura **MetJacobiR** cu sintaxa

$[x_{aprox}, N] = \text{MetJacobiR}(A, a, \varepsilon, \sigma)$.

Parametrii de ieșire sunt: x_{aprox} (soluția aproximativă a sistemului $Ax = a$, calculată prin metoda Jacobi relaxată cu eroarea ε) și N (numărul de iterații necesar pentru obținerea aproximării cu eroarea ε).

În continuare vom prezenta o schemă numerică de calcul al parametrului optim σ_O fără a fi necesar să se calculeze valorile proprii ale matricei A . Parametrul optim va fi ales astfel încât numărul de iterații să fie minim pentru obținerea soluției aproximative cu eroarea relativă ε . Pentru simplificare vom alege norma infinit și vom discretiza intervalul

$\sigma_O \in \left(0, \frac{2}{\|A\|_\infty}\right)$. Fie $(\sigma_s)_{s=\overline{0, p}}$ o discretizare echidistantă a intervalului

$\left[0, \frac{2}{\|A\|_\infty}\right]$. Pasul discretizării este $h = \frac{2}{\|A\|_\infty p}$, iar nodurile

discretizării sunt $\sigma_s = \frac{2s}{\|A\|_\infty p}$, $s = \overline{0, p}$. În algoritmul nu vom include

capetele intervalului $\left(0, \frac{2}{\|A\|_\infty}\right)$, deci $s = \overline{1, p-1}$.

Curs #5

March 26, 2018

22 / 26

4.5. Metoda Gauss - Seidel relaxată

Fie $A \in \mathcal{M}_n(\mathbb{R})$ o matrice simetrică și pozitiv definită, $a \in \mathbb{R}^n$ și $\sigma > 0$ parametru de relaxare. Descompunem matricea $A = L + D + R$. Matricea L este partea inferioară a matricei A , i.e. $l_{ij} = a_{ij}$, $i > j$, $l_{ij} = 0$ în rest. Matricea R este partea superioară a matricei A , i.e. $r_{ij} = a_{ij}$, $i < j$, $r_{ij} = 0$ în rest. Matricea $D = \text{diag}(A)$, i.e. $d_{ii} = a_{ii}$, $d_{ij} = 0$, $i \neq j$.

Avem următoarele sisteme echivalente

$$Ax = a \Leftrightarrow \sigma Ax = \sigma a \Leftrightarrow \sigma(L + D + R)x = \sigma a \Leftrightarrow$$

$$(\sigma L + D + (\sigma - 1)D + \sigma R)x = \sigma a \Leftrightarrow$$

$$(\sigma L + D)x = ((1 - \sigma)D - \sigma R)x + \sigma a \Leftrightarrow$$

$$x = (\sigma L + D)^{-1}((1 - \sigma)D - \sigma R)x + (\sigma L + D)^{-1}\sigma a \Leftrightarrow x = B_\sigma x + b_\sigma$$

unde $B_\sigma = (\sigma L + D)^{-1}((1 - \sigma)D - \sigma R)$, $b_\sigma = (\sigma L + D)^{-1}\sigma a$

Curs #5

March 26, 2018

24 / 26

Teorema (II.14.)

Metoda Gauss - Seidel relaxată este convergentă dacă și numai dacă

$$\sigma \in (0, 2) \quad (22)$$

Dacă $q = \|B_\sigma\|_A$, atunci $q < 1$ și are loc următoare estimare

$$\|x^{(k)} - x\|_A \leq \frac{q^k}{1-q} \|x^{(1)} - x^{(0)}\|_A, \forall k \in \mathbb{N} \quad (23)$$

Componentele $x_i^{(k)}$ se pot calcula evitând calculul inversei matricei $\sigma L + D$. Avem

$$\begin{aligned}
x^{(k)} &= B_\sigma x^{(k-1)} + b_\sigma \\
&\Leftrightarrow (\sigma L + D)x^{(k)} = ((1-\sigma)D - \sigma R)x^{(k-1)} + \sigma a \Rightarrow \\
Dx^{(k)} &= -\sigma Lx^{(k)} + ((1-\sigma)D - \sigma R)x^{(k-1)} + \sigma a \\
&= (1-\sigma)Dx^{(k-1)} - \sigma Rx^{(k-1)} - \sigma Lx^{(k)} + \sigma a \Rightarrow \\
x^{(k)} &= (1-\sigma)x^{(k-1)} + \sigma D^{-1}(a - Rx^{(k-1)} - Lx^{(k)})
\end{aligned}$$

Relația de mai sus scrisă pe componente este:

$$x_i^{(k)} = (1-\sigma)x_i^{(k-1)} + \frac{\sigma}{a_{ii}} \left(a_i - \sum_{j=i+1}^n a_{ij}x_j^{(k-1)} - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} \right) \quad (24)$$

ALGORITM (Metoda Gauss-Seidel relaxată) (Temă)

ALGORITM (Determinarea numerică a parametrului optim prin metoda Gauss-Seidel relaxată) (Temă)